Distributed ML

Ch 3. Splitting the Model

Training Large Model

Large Model size



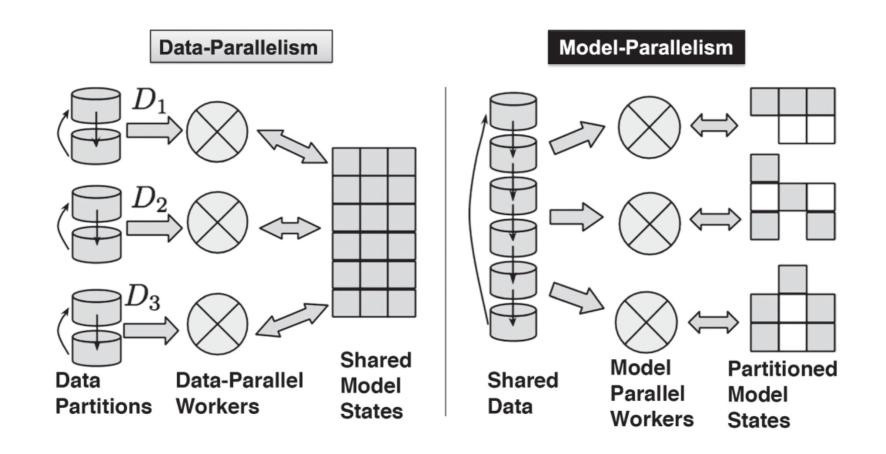
- GPU Memory Size
 - 16GB (2016) -> 32GB (2017) -> 80GB (2020)

Training Large Model

- Large model training on Single-GPU
 - Out of memory 발생
 - Batch size 를 극단적으로 낮추면 가능
 - Parameter precision 을 극단적으로 낮추면 가능
 - 모델을 split 해서 여러 sequence 로 나누어 연산 수행

-> 학습 시간이 극단적으로 증가

Model Parallel



Data parallel

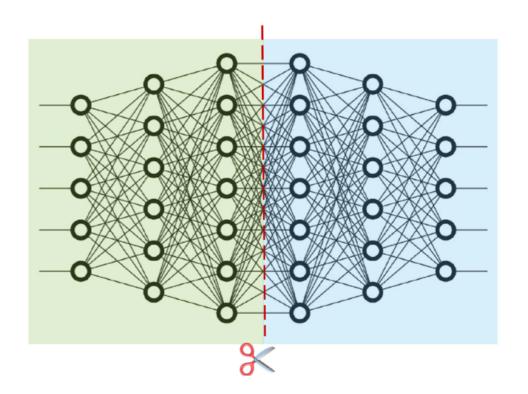
- Dataset 을 분할하여 각 Worker 에 분배
- 각 Worker 간에는 Iter 단위로 N/W 발생
- Grad, weight 와 같이 동일크기의 데이터 교환
- 모든 Worker 는 동일한 용량의 메모리 사용

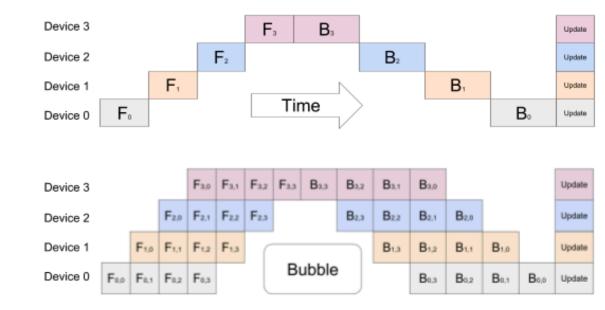
Model parallel

- Weight 와 같은 Parameter 분할하여 분배
- 각 Worker 간에는 Iter 도중에 N/W 발생
- 연산 중간 결과 데이터 를 공유하기에 Worker 별 다른 크기의 데이터 교환
- 분할 방식에 따라 각기 다른 용량의 메모리 사용

How to split the model

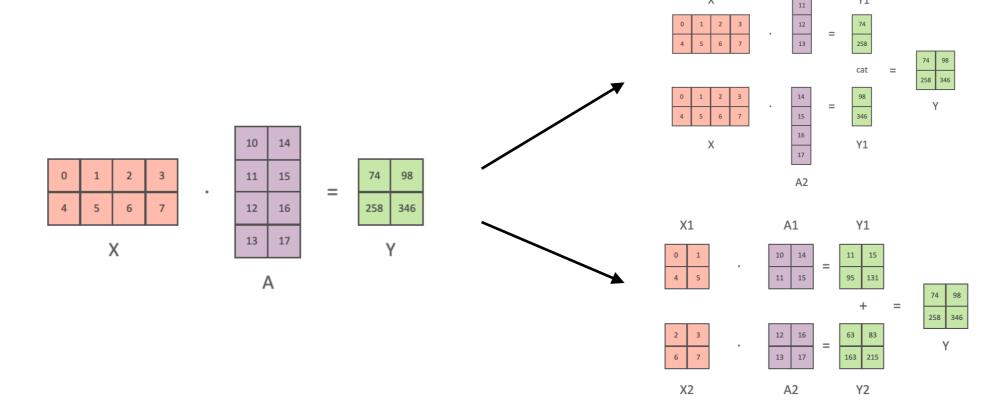
- Inter-layer Parallel (Layer split)
 - 연속된 layer 단위로 분할하여 각 Worker 에 분배
 - 각 Worker 는 중간 결과 값 만을 교환 (N/W 가 단순)
 - 상대적으로 구현이 Simple
 - 완벽한 로드 밸런싱에 취약
 - Bubble 로 인해 GPU 의 Down-time 발생

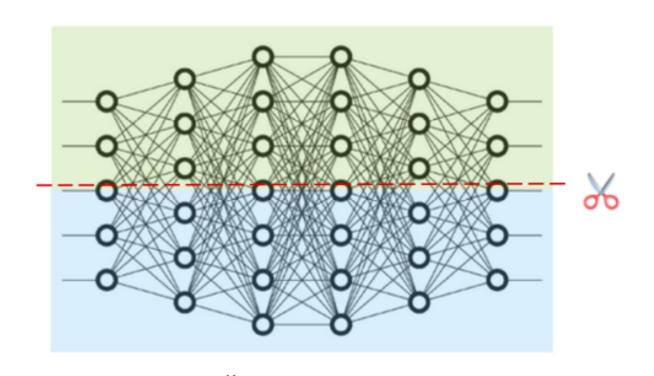




How to split the model

- Intra-layer Parallel (Tensor Split)
 - 개별 layer 내에 Weight 를 분할하여 분배
 - 연산 중간에 Aggregation/Split 반복 (Inter-layer 대비 N/W 증가)
 - 로드 밸런싱이 용이
 - Bubble이 발생하지 않음





Tensor Split

Row-wise split

Column wise split

